

Manual detalhado da modelagem probabilística de janela e forecast

Da série observada à projeção, com derivação de cada objeto matemático

Versão 1.0 - setembro de 2026

Manual técnico e conceitual

probabilistic-window-forecast

Sumário

Como ler este manual	4
1. Problema estatístico	4
1.1 O que significa inferir a janela	5
1.2 O que o método entrega	5
2. Lookback e hipóteses elegíveis	5
3. Centralização e escala robustas	6
3.1 Centro robusto	7
3.2 Escala robusta	7
3.3 Série transformada	7
4. Dinâmicas candidatas para o regime corrente	8
4.1 Modelo constante	8
4.2 Modelo linear	8
4.3 Modelo logarítmico	9
4.4 Por que não escolher visualmente uma família de antemão	9
5. Da função à matriz de desenho	9
5.1 Hipótese sem ruptura	9
5.2 Hipótese com ruptura	10
6. Modelo probabilístico dos dados	11
7. Origem de X transposta X e X transposta z	12
8. Prior normal dos coeficientes	13
8.1 Por que V_0 não é escolhida diagonalmente	13
8.2 Interpretação de g	14
9. Prior da variância residual	14
10. Posterior dos coeficientes, sem saltos algébricos	14
10.1 Expansão da penalidade dos dados	15
10.2 Expansão da penalidade da prior	15
10.3 Agrupamento dos termos	15
10.4 Completação de quadrados	16
10.5 Simplificação com g -prior e $b_0 = 0$	17
11. Exemplo numérico mínimo da posterior	17
12. Posterior da variância residual	19
13. Evidência marginal de uma hipótese	19

13.1 Integração dos coeficientes	19
13.2 Integração da variância	20
14. Priors sobre janela e modelo	20
15. Probabilidade posterior das hipóteses	21
15.1 Probabilidade de uma janela	21
15.2 Probabilidade de um modelo	22
15.3 Conjunto crível de janelas	22
16. Distribuição preditiva de uma hipótese	22
17. Forecast como mistura de hipóteses	23
17.1 Por que os quantis são simulados	24
18. Sensibilidade à força da prior	24
19. Índices de incerteza e revisão humana	25
19.1 O que o revisor pode fazer	25
20. Condicionamento numérico	26
21. Algoritmo completo	26
22. Correspondência com o código Python	27
22.1 Relação direta entre álgebra e NumPy	27
23. Como executar o pacote	28
23.1 Reexecutar com janela escolhida pelo usuário	28
23.2 Forçar ausência de ruptura	28
23.3 Escolher modelo para inspeção	28
24. Como interpretar a saída	29
24.1 Forecast automático versus selecionado	29
24.2 Intervalos	29
24.3 Confiança	29
25. Validação quando não há futuro observado	29
26. Limitações e sinais de alerta	30
27. Por que o método é menos heurístico que uma regra de janela	30
28. Glossário	30
29. Fórmulas essenciais em sequência	31
30. Encadeamento final	32

Este manual explica, passo a passo, a metodologia implementada no pacote `probabilistic-window-forecast`. O objetivo não é apresentar fórmulas prontas, mas mostrar de onde cada expressão vem, o que ela mede e como é usada na etapa seguinte.

O problema tratado é deliberadamente restrito: projetar uma única série mensal X , identificar qual trecho final é compatível com o regime corrente e comparar dinâmicas locais simples. A hierarquia de consolidação e as séries fornecidas pelo usuário ficam fora deste MVP.

Princípio central: dados históricos distantes não devem influenciar o modelo atual como se pertencessem automaticamente ao mesmo regime. Entretanto, eles também não devem ser descartados sem custo. Cada hipótese precisa explicar o lookback completo e justificar probabilisticamente onde o regime atual começa.

Como ler este manual

O texto segue a mesma cadeia do notebook `overview_matematico.ipynb`:

- 1 preparar a série;
- 2 construir hipóteses de janela e dinâmica;
- 3 escrever o modelo probabilístico;
- 4 combinar prior e dados;
- 5 calcular a evidência de cada hipótese;
- 6 transformar evidências em probabilidades;
- 7 projetar cada hipótese;
- 8 combinar projeções e decompor a incerteza;
- 9 decidir se o resultado precisa de revisão humana.

Os quadros chamados **Interpretação** traduzem a álgebra. Os quadros chamados **Na implementação** indicam onde o conceito aparece no código.



Fluxo completo da metodologia

1. Problema estatístico

Temos uma série mensal observada até o instante atual:

$$\mathbf{y} = (y_1, y_2, \dots, y_n)^T$$

Queremos responder simultaneamente:

- houve uma mudança de regime dentro do `lookback`?
- se houve, em qual mês o regime atual começou?
- o regime corrente é mais compatível com nível constante, reta ou curva logarítmica?
- qual é a distribuição dos valores futuros?
- quanto da incerteza vem do ruído e quanto vem da dúvida sobre janela e modelo?

Não tratamos a janela como uma decisão tomada antes da modelagem. Janela e modelo formam conjuntamente uma hipótese:

$$h = (m, \tau)$$

Aqui, `m` identifica a família funcional e `tau` identifica o início do regime corrente. O símbolo `tau = vazio` representa a hipótese sem ruptura: uma única dinâmica explica todo o `lookback`.

1.1 O que significa inferir a janela

Uma hipótese de janela curta não usa somente os pontos recentes e ignora o restante. Ela usa uma função auxiliar para o período anterior e uma função para o regime corrente. Assim, todas as hipóteses explicam os mesmos `n` pontos.

Isso impede uma comparação injusta. Se um modelo pudesse apagar observações difíceis apenas escolhendo uma janela menor, o melhor resultado tenderia a ser a menor janela permitida.

1.2 O que o método entrega

O resultado não é apenas um nome de modelo. Ele contém:

- probabilidade de não ter ocorrido mudança;
- distribuição de probabilidade sobre possíveis inícios de regime;
- probabilidade marginal de cada família funcional;
- forecast automático, integrando todas as hipóteses;
- forecast condicionado à janela e ao modelo selecionados;
- intervalos preditivos;
- variância dentro das hipóteses e entre hipóteses;
- sensibilidade à força da prior;
- diagnóstico numérico;
- indicação de revisão humana.

2. Lookback e hipóteses elegíveis

Se a série tem mais observações que `max_lookback`, apenas as últimas `max_lookback` observações entram no procedimento. Esse limite é operacional: ele evita comparar regimes extremamente antigos e controla o custo computacional.

Para uma ruptura candidata no índice `k`, são exigidos:

$$k \geq n_{\text{antes}}$$

e


$$n - k \geq n_{\text{depois}}$$

Os parâmetros `min_before` e `min_after` garantem dados mínimos nos dois lados. Sem essa proteção, uma ruptura muito perto da borda poderia criar coeficientes praticamente não identificáveis.

Se existem K datas elegíveis e M modelos candidatos, o número de hipóteses é:

$$M(K + 1)$$

O termo adicional corresponde à hipótese sem ruptura.



Série sintética com múltiplos regimes históricos e foco no regime terminal

O procedimento admite no máximo uma ruptura terminal por hipótese. A série pode ter tido várias mudanças históricas, mas o bloco anterior é resumido por uma reta auxiliar. O alvo da inferência é o início do regime que chega até hoje.

3. Centralização e escala robustas

Modelos com unidades muito diferentes criam problemas numéricos e tornam uma prior fixa impossível de interpretar. Por isso cada série é transformada antes da estimação.

3.1 Centro robusto

Calculamos a mediana:

$$c_y = \text{mediana}(y_1, \dots, y_n)$$

A mediana é menos sensível a poucos valores extremos que a média.

3.2 Escala robusta

Primeiro calculamos o desvio absoluto mediano:

$$MAD = \text{mediana}(|y_t - c_y|)$$

Depois aplicamos o fator de consistência normal:

$$s_y = 1,4826 MAD$$

Sob dados aproximadamente normais, s_y fica na escala do desvio-padrão. Se o MAD for quase zero, a implementação usa uma escala de segurança baseada no desvio-padrão, no nível da série ou em 1.

3.3 Série transformada

Cada observação passa a ser:

$$Z_t = \frac{y_t - c_y}{s_y}$$

Em notação vetorial:

$$z = \frac{y - c_y}{s_y}$$

O mesmo centro e a mesma escala são usados em todas as hipóteses. Isso é essencial: evidências só são comparáveis quando representam a mesma variável.

Para retornar à unidade original:

$$y_t = c_y + s_y z_t$$

Interpretação. Depois da transformação, intercepto zero significa o nível típico da própria série. Uma inclinação igual a 0,2 representa crescimento de 0,2 escalas robustas por mês, e não crescimento de 0,2 unidade original.

4. Dinâmicas candidatas para o regime corrente

Definimos $u = 0, 1, 2, \dots$ como a idade de cada ponto desde o início do regime corrente. Usar a idade, e não o índice absoluto da série, torna os coeficientes comparáveis entre janelas.

4.1 Modelo constante

$$f_{const}(u) = \alpha$$

Vetor de base:

$$\phi_{const}(u) = [1]$$

O modelo representa um patamar com flutuações aleatórias.

4.2 Modelo linear

$$f_{lin}(u) = \alpha + bu$$

Vetor de base:

$$\phi_{lin}(u) = [1, u]$$

O coeficiente b mede a mudança média por mês na escala padronizada.

4.3 Modelo logarítmico

$$f_{log}(u) = \alpha + b \log(1 + u)$$

Vetor de base:

$$\phi_{log}(u) = [1, \log(1 + u)]$$

A derivada é:

$$\frac{df_{log}(u)}{du} = \frac{b}{1 + u}$$

Portanto, a direção é controlada pelo sinal de b , mas a intensidade diminui com o tempo. Esse formato oferece curvatura sem a extrapolação explosiva de um polinômio quadrático.

4.4 Por que não escolher visualmente uma família de antemão

Uma reta pode parecer adequada no histórico e ainda produzir projeção frágil quando sua inclinação é mal estimada. O método compara as famílias pela probabilidade dos dados depois de integrar a incerteza dos coeficientes. A visualização continua importante, mas funciona como diagnóstico e possível intervenção, não como substituto silencioso da inferência.

5. Da função à matriz de desenho

Uma regressão linear nos parâmetros pode ser escrita como:

$$\mathbf{z} = \mathbf{X}_h \boldsymbol{\beta}_h + \boldsymbol{\varepsilon}$$

Cada linha de $\mathbf{X}_h$ informa quais coeficientes participam da média de uma observação. Cada coluna representa um coeficiente desconhecido.

5.1 Hipótese sem ruptura

Para um modelo linear com quatro observações e idades 0, 1, 2, 3:

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}$$

e

$$\boldsymbol{\beta} = [\alpha, b]^T$$

O produto $\mathbf{X} \boldsymbol{\beta}$ produz:

$$\mathbf{X}\boldsymbol{\beta} = [\alpha, \alpha + b, \alpha + 2b, \alpha + 3b]^T$$

5.2 Hipótese com ruptura

Suponha uma ruptura em k . Antes dela usamos uma reta auxiliar:

$$g_{pre}(t) = a_{pre} + b_{pre}t$$

Depois dela usamos a família candidata do regime corrente. Para um regime corrente linear, o vetor de coeficientes é:

$$\boldsymbol{\beta} = [a_{pre}, b_{pre}, \alpha, b]^T$$

Uma matriz ilustrativa com três pontos antes e três depois é:

$$\mathbf{X} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 2 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 2 \end{bmatrix}$$

Os zeros desligam o bloco que não pertence à observação. Não é imposta continuidade na ruptura: uma mudança de nível pode ocorrer junto com uma mudança de direção.

Interpretação. A reta anterior não é o objeto que queremos projetar. Ela é um mecanismo para cobrar da hipótese uma explicação pelo passado sem forçar o regime atual a reproduzi-lo.

6. Modelo probabilístico dos dados

Para uma hipótese h , assumimos:

$$\mathbf{z} \mid \boldsymbol{\beta}_h, \sigma^2, h \sim N(\mathbf{X}_h \boldsymbol{\beta}_h, \sigma^2 \mathbf{I})$$

Isso equivale a escrever:

$$\mathbf{z} = \mathbf{X}_h \boldsymbol{\beta}_h + \boldsymbol{\varepsilon}$$

com

$$\boldsymbol{\varepsilon} \sim N(0, \sigma^2 \mathbf{I})$$

A matriz identidade expressa três suposições:

- mesma variância residual em todos os meses;
- ausência de correlação serial residual;
- erro aditivo na escala transformada.

A densidade é o produto de um fator de normalização,

$$(2\pi\sigma^2)^{-n/2},$$

e de um fator que diminui com o erro quadrático:

$$\exp\left[-\frac{1}{2\sigma^2}(\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^T(\mathbf{z} - \mathbf{X}\boldsymbol{\beta})\right].$$

Portanto, a densidade completa é o produto desses dois fatores.

O expoente penaliza a soma de erros quadráticos. Quanto maior o erro, menor a verossimilhança.

7. Origem de $\mathbf{X}^T \mathbf{X}$ e $\mathbf{X}^T \mathbf{z}$

Começamos pela soma de quadrados:

$$Q(\boldsymbol{\beta}) = (\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^T(\mathbf{z} - \mathbf{X}\boldsymbol{\beta})$$

Distribuindo o produto:

$$\begin{aligned} Q(\boldsymbol{\beta}) &= \mathbf{z}^T \mathbf{z} - \mathbf{z}^T \mathbf{X}\boldsymbol{\beta} \\ &\quad - \boldsymbol{\beta}^T \mathbf{X}^T \mathbf{z} \\ &\quad + \boldsymbol{\beta}^T \mathbf{X}^T \mathbf{X}\boldsymbol{\beta} \end{aligned}$$

O produto $\mathbf{z}^T \mathbf{X}\boldsymbol{\beta}$ é um escalar. A transposta de um escalar é o próprio escalar, portanto:

$$\mathbf{z}^T \mathbf{X}\boldsymbol{\beta} = \boldsymbol{\beta}^T \mathbf{X}^T \mathbf{z}$$

Assim:

$$Q(\boldsymbol{\beta}) = \mathbf{z}^T \mathbf{z} - 2\boldsymbol{\beta}^T \mathbf{X}^T \mathbf{z} + \boldsymbol{\beta}^T \mathbf{X}^T \mathbf{X}\boldsymbol{\beta}$$

Agora aparecem dois objetos:

$$\mathbf{X}^T \mathbf{X} \quad \text{e} \quad \mathbf{X}^T \mathbf{z}$$

$\mathbf{X}^T \mathbf{X}$ controla a curvatura de Q . Direções com grande curvatura são fortemente penalizadas quando se afastam do melhor ajuste e, por isso, são estimadas com maior precisão. $\mathbf{X}^T \mathbf{z}$ aponta para a combinação de coeficientes favorecida pelos dados.

Derivando Q em relação a $\boldsymbol{\beta}$:

$$\begin{aligned} \frac{\partial Q}{\partial \boldsymbol{\beta}} \\ = -2\mathbf{X}^T \mathbf{z} + 2\mathbf{X}^T \mathbf{X}\boldsymbol{\beta} \end{aligned}$$

No mínimo, a derivada vale zero:

$$\mathbf{X}^T \mathbf{X} \hat{\boldsymbol{\beta}}_{OLS} = \mathbf{X}^T \mathbf{z}$$

Se $\mathbf{X}$ transposta $\mathbf{X}$ for invertível:

$$\hat{\boldsymbol{\beta}}_{OLS} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{z}$$

8. Prior normal dos coeficientes

Antes de observar os dados, usamos:

$$\boldsymbol{\beta} \mid \sigma^2, h \sim N(\mathbf{b}_0, \sigma^2 \mathbf{V}_0)$$

Há três objetos diferentes nessa expressão:

- $\mathbf{b}_0$: centro anterior dos coeficientes;
- $\mathbf{V}_0$: geometria e dispersão relativa da prior;
- σ^2 quadrado: escala global de ruído compartilhada com a verossimilhança.

No pacote:

$$\mathbf{b}_0 = \mathbf{0}$$

Depois da centralização, isso representa ausência de deslocamento e tendência como referência fraca, não a afirmação de que a série real vale zero.

8.1 Por que $\mathbf{V}_0$ não é escolhida diagonalmente

Uma variância fixa para cada coeficiente depende das unidades das colunas de $\mathbf{X}$. A coluna do intercepto e a coluna de tempo têm escalas diferentes. Além disso, a escala da coluna temporal muda com o tamanho da janela.

A g-prior usa a geometria do próprio desenho:

$$\mathbf{V}_0 = g(\mathbf{X}^T \mathbf{X})^{-1}$$

Logo, sua precisão é:

$$\mathbf{V}_0^{-1} = \frac{1}{g} \mathbf{X}^T \mathbf{X}$$

Essa escolha adapta a prior à unidade e à correlação das colunas. O parâmetro escalar g controla sua força.

8.2 Interpretação de g

Precisão maior significa distribuição mais concentrada. Como a precisão da prior é $1/g$ vezes a precisão total dos dados:

- g pequeno cria regularização mais forte;
- g grande cria prior mais difusa;
- $g = n$ produz aproximadamente a informação média de uma observação.

O padrão do pacote é:

$$g = n$$

Essa convenção é chamada prior de informação unitária. Ela é reproduzível, mas não é uma verdade sobre o negócio. Por isso sua sensibilidade é medida.

9. Prior da variância residual

Usamos uma distribuição Inverse-Gamma:

$$\sigma^2 \sim IG(a_0, d_0)$$

Na parametrização do pacote:

$$p(\sigma^2) \propto (\sigma^2)^{-(a_0 + 1)} \exp\left(-\frac{d_0}{\sigma^2}\right)$$

a_0 controla a forma e a quantidade de regularização. d_0 determina a escala anterior do ruído depois da padronização robusta. Os padrões são fracos, mas evitam problemas em amostras curtas ou ajustes quase perfeitos.

10. Posterior dos coeficientes, sem saltos algébricos

Esta é a etapa em que a informação anterior e a informação dos dados são combinadas.

A parte da log-verossimilhança que depende de β é proporcional a:

$$-\frac{1}{2\sigma^2}(\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^T(\mathbf{z} - \mathbf{X}\boldsymbol{\beta})$$

A parte da log-prior que depende de **beta** é proporcional a:

$$-\frac{1}{2\sigma^2}(\boldsymbol{\beta} - \mathbf{b}_0)^T \mathbf{V}_0^{-1}(\boldsymbol{\beta} - \mathbf{b}_0)$$

Multiplicar densidades equivale a somar logaritmos. Portanto, somamos as duas penalidades.

10.1 Expansão da penalidade dos dados

$$\begin{aligned} &(\mathbf{z} - \mathbf{X}\boldsymbol{\beta})^T(\mathbf{z} - \mathbf{X}\boldsymbol{\beta}) \\ &= \mathbf{z}^T \mathbf{z} - 2\boldsymbol{\beta}^T \mathbf{X}^T \mathbf{z} \\ &\quad + \boldsymbol{\beta}^T \mathbf{X}^T \mathbf{X} \boldsymbol{\beta} \end{aligned}$$

10.2 Expansão da penalidade da prior

Como $\mathbf{V}_0^{-1}$ é simétrica:

$$\begin{aligned} &(\boldsymbol{\beta} - \mathbf{b}_0)^T \mathbf{V}_0^{-1}(\boldsymbol{\beta} - \mathbf{b}_0) \\ &= \boldsymbol{\beta}^T \mathbf{V}_0^{-1} \boldsymbol{\beta} \\ &\quad - 2\boldsymbol{\beta}^T \mathbf{V}_0^{-1} \mathbf{b}_0 \\ &\quad + \mathbf{b}_0^T \mathbf{V}_0^{-1} \mathbf{b}_0 \end{aligned}$$

10.3 Agrupamento dos termos

Somando as expansões e agrupando por potência de **beta**:

$$\begin{aligned} &\boldsymbol{\beta}^T (\mathbf{X}^T \mathbf{X} + \mathbf{V}_0^{-1}) \boldsymbol{\beta} \\ &- 2\boldsymbol{\beta}^T (\mathbf{X}^T \mathbf{z} + \mathbf{V}_0^{-1} \mathbf{b}_0) + C \end{aligned}$$

C reúne os termos que não dependem de **beta**:

$$C = \mathbf{z}^T \mathbf{z} + \mathbf{b}_0^T \mathbf{V}_0^{-1} \mathbf{b}_0$$

Os termos em **beta** não se anulam. O termo quadrático recebe a soma das precisões, e o termo linear recebe a soma das informações que determinam o centro.

Definimos:

$$\mathbf{A} = \mathbf{X}^T \mathbf{X} + \mathbf{V}_0^{-1}$$

e

$$\mathbf{c} = \mathbf{X}^T \mathbf{z} + \mathbf{V}_0^{-1} \mathbf{b}_0$$

A expressão dependente de β é:

$$\beta^T \mathbf{A} \beta - 2\beta^T \mathbf{c}$$

10.4 Completação de quadrados

Queremos reescrever a expressão em torno de um novo centro $\mathbf{b}_n$. Expandimos:

$$(\beta - \mathbf{b}_n)^T \mathbf{A} (\beta - \mathbf{b}_n)$$

O resultado é:

$$\begin{aligned} & \beta^T \mathbf{A} \beta \\ & - 2\beta^T \mathbf{A} \mathbf{b}_n + \mathbf{b}_n^T \mathbf{A} \mathbf{b}_n \end{aligned}$$

Para o termo linear coincidir com $-2 \beta^T \mathbf{c}$, precisamos de:

$$\mathbf{A} \mathbf{b}_n = \mathbf{c}$$

Logo:

$$\mathbf{b}_n = \mathbf{A}^{-1} \mathbf{c}$$

Substituindo as definições:

$$\mathbf{V}_n = (\mathbf{V}_0^{-1} + \mathbf{X}^T \mathbf{X})^{-1}$$

e

$$\mathbf{b}_n = \mathbf{V}_n(\mathbf{V}_0^{-1}\mathbf{b}_0 + \mathbf{X}^T\mathbf{z})$$

Portanto:

$$\boldsymbol{\beta} \mid \sigma^2, \mathbf{z}, h \sim N(\mathbf{b}_n, \sigma^2\mathbf{V}_n)$$

Não são as covariâncias que se somam. Somam-se as precisões. A covariância posterior é obtida invertendo a precisão total.

10.5 Simplificação com g-prior e $\mathbf{b}_0 = \mathbf{0}$

Com a g-prior:

$$\mathbf{V}_0^{-1} = \frac{1}{g}\mathbf{X}^T\mathbf{X}$$

Assim:

$$\mathbf{V}_n^{-1} = \left(1 + \frac{1}{g}\right)\mathbf{X}^T\mathbf{X}$$

O centro posterior vira:

$$\mathbf{b}_n = \frac{g}{g+1}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{z}$$

Como o termo final é o estimador OLS:

$$\mathbf{b}_n = \frac{g}{g+1}\hat{\boldsymbol{\beta}}_{OLS}$$

Para $g = n$, os coeficientes OLS são contraídos pelo fator $n/(n+1)$.

11. Exemplo numérico mínimo da posterior

Considere três observações padronizadas:

$$\mathbf{z} = [0, 1, 2]^T$$

e um modelo linear com:

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}$$

Primeiro:

$$\mathbf{X}^T \mathbf{X} = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}$$

e

$$\mathbf{X}^T \mathbf{z} = [3, 5]^T$$

O ajuste OLS resolve:

$$\begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix} \hat{\boldsymbol{\beta}}_{OLS} = [3, 5]^T$$

resultando em:

$$\hat{\boldsymbol{\beta}}_{OLS} = [0, 1]^T$$

Com $g = n = 3$ e $b_0 = 0$:

$$\mathbf{b}_n = \frac{3}{4}[0, 1]^T = [0, 0,75]^T$$

A inclinação é levemente puxada para zero. Se g fosse 99, o fator seria $99/100$, quase sem regularização. Se g fosse 1, o fator seria $1/2$.

12. Posterior da variância residual

Depois de completar o quadrado em β , a prior Inverse-Gamma também é atualizada. O parâmetro de forma é:

$$a_n = a_0 + \frac{n}{2}$$

Cada observação adiciona meia unidade porque a densidade normal contém a potência (σ^2 elevado a $-n/2$).

O parâmetro de escala é:

$$d_n = d_0 + \frac{1}{2}(\mathbf{z}^T \mathbf{z} + \mathbf{b}_0^T \mathbf{V}_0^{-1} \mathbf{b}_0 - \mathbf{b}_n^T \mathbf{V}_n^{-1} \mathbf{b}_n)$$

O primeiro termo mede a energia bruta dos dados. O segundo incorpora a posição da prior. O terceiro subtrai a parte explicada quando deslocamos a distribuição para o centro posterior.

Quando $a_n > 1$, a média posterior é:

$$E[\sigma^2 \mid \mathbf{z}, h] = \frac{d_n}{a_n - 1}$$

Essa quantidade é retornada na unidade original após multiplicação por s_y ao quadrado.

13. Evidência marginal de uma hipótese

Comparar apenas o erro no melhor ajuste favoreceria modelos flexíveis. A evidência marginal avalia toda a região de parâmetros permitida pela prior:

$$p(\mathbf{z} \mid h) = \int \int p(\mathbf{z} \mid \boldsymbol{\beta}, \sigma^2, h) p(\boldsymbol{\beta} \mid \sigma^2, h) p(\sigma^2) d\boldsymbol{\beta} d\sigma^2$$

13.1 Integração dos coeficientes

A completção de quadrados transforma a parte em β numa densidade normal posterior. Integrar essa densidade produz o fator:

$$\frac{|\mathbf{V}_n|^{1/2}}{|\mathbf{V}_0|^{1/2}}$$

O determinante mede volume. Se apenas uma região muito pequena do espaço anterior explica os dados, há forte compressão de volume. Esse é um componente da penalização automática de complexidade.

13.2 Integração da variância

Depois da integração de `beta`, resta o núcleo de uma Inverse-Gamma com parâmetros `an` e `dn`. Sua integral produz:

$$\frac{d_0^{a_0} \Gamma(a_n)}{d_n^{a_n} \Gamma(a_0)}$$

Juntando os fatores, a evidência pode ser lida como o produto de duas partes. A primeira vem da normal e da integração dos coeficientes:

$$(2\pi)^{-n/2} \frac{|\mathbf{V}_n|^{1/2}}{|\mathbf{V}_0|^{1/2}}.$$

A segunda vem da integração da variância:

$$\frac{d_0^{a_0} \Gamma(a_n)}{d_n^{a_n} \Gamma(a_0)}.$$

Logo, $p(\mathbf{z} \mid \mathbf{h})$ é o produto dessas duas expressões.

Interpretação. Um modelo vence quando encontra bom compromisso entre ajuste e volume de parâmetros plausíveis. Flexibilidade só ajuda se melhorar os dados o suficiente para compensar a dispersão adicional.

Na implementação, a evidência é calculada em logaritmos:

$$\log p(\mathbf{z} \mid \mathbf{h})$$

Isso evita underflow ao multiplicar números muito pequenos.

14. Priors sobre janela e modelo

Além das priors dos parâmetros, precisamos de uma prior sobre as hipóteses.

Se `pi0` é a probabilidade anterior de não haver ruptura:

$$P(\tau = \emptyset) = \pi_0$$

Se há K datas elegíveis:

$$P(\tau = k) = \frac{1 - \pi_0}{K}$$

Cada modelo recebe peso $P(m)$. A prior conjunta é:

$$P(h) = P(m)P(\tau)$$

O padrão distribui igualmente a massa entre as famílias e usa probabilidade anterior de 0,60 para a hipótese sem mudança. Isso expressa parcimônia: uma ruptura precisa de evidência para superar a alternativa mais simples.

15. Probabilidade posterior das hipóteses

Aplicando o teorema de Bayes:

$$P(h \mid \mathbf{z}) = \frac{p(\mathbf{z} \mid h)P(h)}{\sum_{h'} p(\mathbf{z} \mid h')P(h')}$$

Computacionalmente, definimos:

$$\ell_h = \log p(\mathbf{z} \mid h) + \log P(h)$$

e calculamos:

$$P(h \mid \mathbf{z}) = \exp(\ell_h - \text{logsumexp}(\ell_1, \dots, \ell_H))$$

O `logsumexp` normaliza sem exponenciar diretamente números extremos.

15.1 Probabilidade de uma janela

Uma mesma janela aparece combinada com vários modelos. Sua probabilidade é a soma das hipóteses correspondentes:

$$P(\tau \mid \mathbf{z}) = \sum_m P(m, \tau \mid \mathbf{z})$$

15.2 Probabilidade de um modelo

Analogamente:

$$P(m \mid \mathbf{z}) = \sum_{\tau} P(m, \tau \mid \mathbf{z})$$

Essa marginalização é importante. A janela recomendada não precisa pertencer à mesma hipótese conjunta que possui a maior probabilidade individual; ela é a janela com maior suporte somado entre modelos.

15.3 Conjunto crível de janelas

Ordenamos as janelas por probabilidade e as acumulamos até atingir `credible_mass`, cujo padrão é 90%. O conjunto resultante mostra quais datas de início concentram a maior parte da plausibilidade posterior.

16. Distribuição preditiva de uma hipótese

Para um horizonte futuro, construímos a linha de desenho `x_estrela`. Em uma hipótese com ruptura, ela utiliza apenas o bloco do regime corrente; o bloco anterior recebe zeros.

Condicionalmente a `beta` e `sigma quadrado`:

$$z_* \mid \boldsymbol{\beta}, \sigma^2, h \sim N(\mathbf{x}_*^T \boldsymbol{\beta}, \sigma^2)$$

Integrar `beta` adiciona a incerteza dos coeficientes:

$$z_* \mid \sigma^2, \mathbf{z}, h \sim N(\mathbf{x}_*^T \mathbf{b}_n, \sigma^2(1 + \mathbf{x}_*^T \mathbf{V}_n \mathbf{x}_*))$$

O termo 1 representa um novo choque residual. O termo quadrático representa a incerteza dos coeficientes projetada na direção do ponto futuro.

Integrar `sigma quadrado` produz uma Student-t:

$$z_* \mid \mathbf{z}, h \sim t_{2a_n}(\mu_h, q_h^2)$$

com

$$\mu_h = \mathbf{x}_*^T \mathbf{b}_n$$

e

$$q_h^2 = \frac{d_n}{a_n} (1 + \mathbf{x}_*^T \mathbf{V}_n \mathbf{x}_*)$$

Se $\nu = 2$ a_n é maior que 2, a variância é:

$$\text{Var}(z_* \mid \mathbf{z}, h) = q_h^2 \frac{\nu}{\nu - 2}$$

Na unidade original:

$$E[Y_* \mid \mathbf{y}, h] = c_y + s_y \mu_h$$

e

$$\text{Var}(Y_* \mid \mathbf{y}, h) = s_y^2 \text{Var}(z_* \mid \mathbf{z}, h)$$

17. Forecast como mistura de hipóteses

Selecionar uma hipótese e fingir certeza descartaria informação. O forecast automático integra janela e modelo:

$$p(y_* \mid \mathbf{y}) = \sum_h p(y_* \mid \mathbf{y}, h) P(h \mid \mathbf{y})$$


Se w_h é o peso posterior e μ_h é a média da hipótese:

$$\mu = \sum_h w_h \mu_h$$

A lei da variância total fornece:

$$\text{Var}(Y_*) = \sum_h w_h v_h + \sum_h w_h (\mu_h - \mu)^2$$

O primeiro termo é a variância **dentro das hipóteses**. Ele inclui ruído futuro e incerteza dos coeficientes. O segundo é a variância **entre hipóteses**. Ele mede a discordância provocada por diferentes janelas e modelos.



Decomposição conceitual da incerteza preditiva

17.1 Por que os quantis são simulados

Uma média ponderada de distribuições Student-t geralmente não é outra Student-t. Por isso o pacote:

- 1 sorteia quantas amostras virão de cada hipótese de acordo com seus pesos;
- 2 gera amostras da preditiva de cada hipótese;
- 3 concatena as amostras;
- 4 calcula mediana e quantis empíricos.

O intervalo é preditivo: ele inclui um novo erro residual. Portanto, é mais largo que um intervalo apenas para a média estimada.

18. Sensibilidade à força da prior

Uma resposta automática não deve depender de uma escolha arbitrária não inspecionada. O pacote repete a inferência para:

$$g \in \{n/2, n, 2n\}$$

Para cada valor, recalcula prior, posterior, evidências, probabilidades e forecast.

`prior_sensitive` é verdadeiro quando a janela ou o modelo recomendado muda.

A amplitude normalizada das médias projetadas é:

$$S_g = \max_{1 \leq r \leq H} \frac{\max_g \mu_{r,g} - \min_g \mu_{r,g}}{s_y}$$

Dividir por s_y permite comparar séries em unidades diferentes.

Interpretação. Sensibilidade não prova que a prior esteja errada. Ela mostra que os dados disponíveis não dominam completamente decisões plausíveis sobre regularização.

19. Índices de incerteza e revisão humana

Para horizonte H , o índice de incerteza preditiva é:

$$U_{total} = \frac{1}{H} \sum_{r=1}^H \frac{V_{total,r}}{s_y^2}$$

O índice de incerteza de seleção usa apenas a parcela entre hipóteses:

$$U_{sel} = \frac{1}{H} \sum_{r=1}^H \frac{V_{entre,r}}{s_y^2}$$

Com materialidade M :

$$L = MU_{sel}$$

A revisão é recomendada quando:

$$L > C_{review}$$

ou quando a seleção é sensível a g .

O custo de revisão não altera a posterior. Ele é uma regra operacional aplicada depois da inferência.

19.1 O que o revisor pode fazer

O usuário pode:

- selecionar visualmente o início do regime;
- forçar a hipótese sem mudança;
- alternar entre modelos na janela selecionada;

- escolher explicitamente um modelo;
- executar novamente e comparar o forecast condicionado.

O resultado registra se janela e modelo vieram da decisão automática ou manual.

20. Condicionamento numérico

A g-prior exige inverter $X^T X$. Se duas colunas de X forem quase combinações uma da outra, alguns coeficientes não são separadamente identificados.

O número de condição é:

$$\kappa(\mathbf{X}) = \frac{s_{\max}(\mathbf{X})}{s_{\min}(\mathbf{X})}$$

Os termos $s_{\max}$ e $s_{\min}$ são o maior e o menor valor singular. Quando o menor é quase zero, pequenas perturbações nos dados podem causar grandes mudanças nos coeficientes.

Hipóteses acima de `max_design_condition_number` são rejeitadas. Isso não é um critério estatístico de escolha do melhor modelo; é uma proteção contra uma operação numericamente não confiável.

21. Algoritmo completo

entrada: observações mensais (valor, t)

1. validar, ordenar conforme recebido e limitar o lookback
2. calcular mediana, MAD e série padronizada z
3. enumerar modelos candidatos
4. enumerar hipótese sem ruptura e todas as rupturas elegíveis
5. para cada hipótese h :
 - construir X_h
 - verificar condicionamento
 - construir g-prior
 - calcular V_n , b_n , a_n e d_n
 - calcular log-evidência
6. adicionar log-prior de cada hipótese
7. normalizar com `logsumexp`
8. marginalizar probabilidades por janela e por modelo
9. repetir para g em $\{n/2, n, 2n\}$
10. para cada horizonte:
 - calcular preditiva de cada hipótese
 - combinar pela probabilidade posterior
 - decompor variância dentro/entre hipóteses
 - simular quantis da mistura
11. calcular índices de incerteza e perda operacional
12. emitir recomendação automática e flag de revisão
13. se houver override humano, condicionar e recalculando o forecast selecionado

22. Correspondência com o código Python

Conceito	Implementação
observação	<code>Observation</code>
configuração	<code>BayesianConfig</code>
pipeline público	<code>BayesianForecastPipeline</code>
base funcional	<code>_basis</code>
matriz de desenho	<code>_design_matrix</code>
ajuste de uma hipótese	<code>_fit_hypothesis</code>
normalização posterior	<code>_normalize_hypotheses</code>
probabilidades de janela	<code>_window_probabilities</code>
probabilidades de modelo	<code>_model_probabilities</code>
conjunto crível	<code>_credible_set</code>
preditiva de uma hipótese	<code>_predictive_moments</code> e <code>_predictive_samples</code>
mistura	<code>_mixture_forecast</code>
sensibilidade	<code>_g_sensitivity</code>
resultado	<code>BayesianResult</code>

22.1 Relação direta entre álgebra e NumPy

```

b0 = np.zeros(design.shape[1])
data_precision = design.T @ design
g_value = len(z) * g_multiplier

v0 = g_value * np.linalg.inv(data_precision)
v0_inv = data_precision / g_value

vn = np.linalg.inv(v0_inv + data_precision)
bn = vn @ (v0_inv @ b0 + design.T @ z)

an = noise_shape + len(z) / 2.0
dn = noise_scale + 0.5 * (
    z @ z
    + b0 @ v0_inv @ b0
    - bn @ np.linalg.solve(vn, bn)
)

```

Linha por linha:

- `design.T @ design` calcula a precisão fornecida pelos dados;
- `v0_inv` é a precisão da g-prior;
- `v0_inv + data_precision` soma as precisões;
- sua inversa é a covariância relativa posterior `vn`;
- `design.T @ z` é a informação linear dos dados;
- `v0_inv @ b0` é a informação linear da prior;

- `bn` resolve o novo centro;
- `an` e `dn` atualizam a distribuição do ruído.

23. Como executar o pacote

```
from probabilistic_window_forecast import (
    BayesianConfig,
    BayesianForecastPipeline,
)

observations = [
    (102.0, "2024-01"),
    (101.5, "2024-02"),
    (103.2, "2024-03"),
    # ...
]

config = BayesianConfig(
    max_lookback=60,
    min_before=8,
    min_after=8,
    forecast_horizon=6,
)

pipeline = BayesianForecastPipeline(config)
result = pipeline.run(observations, series_id="serie_x")
```

Principais leituras:

```
result.recommended_window_start_t
result.window_credible_set
result.recommended_model
result.model_probabilities
result.forecast
result.selection_uncertainty_index
result.prior_sensitive
result.human_intervention_required
```

23.1 Reexecutar com janela escolhida pelo usuário

```
adjusted = pipeline.run(
    observations,
    series_id="serie_x",
    window_start="2025-01",
)
```

23.2 Forçar ausência de ruptura

```
adjusted = pipeline.run(
    observations,
    series_id="serie_x",
    force_no_change=True,
)
```

23.3 Escolher modelo para inspeção

```
adjusted = pipeline.run(
    observations,
    series_id="serie_x",
    window_start="2025-01",
    model_override="linear",
)
```

24. Como interpretar a saída

24.1 Forecast automático versus selecionado

`forecast` integra todas as hipóteses com seus pesos posteriores. É a previsão probabilística oficial antes de decisão humana.

`selected_forecast` condiciona na janela e no modelo efetivamente selecionados. Ele é útil para visualizar o efeito de um override, mas elimina deliberadamente parte da incerteza de seleção.

24.2 Intervalos

Para cada horizonte, `PredictivePoint` contém:

- `mean`: média da mistura;
- `median`: mediana simulada;
- `lower` e `upper`: limites do intervalo preditivo;
- `within_hypothesis_variance`: ruído e coeficientes;
- `between_hypothesis_variance`: discordância de seleção;
- `total_variance`: soma das duas parcelas.

24.3 Confiança

O pacote evita reduzir toda a qualidade a um único score arbitrário. A confiança deve ser lida por meio de:

- concentração das probabilidades de janela;
- concentração das probabilidades de modelo;
- largura do conjunto crível de janelas;
- proporção da variância entre hipóteses;
- sensibilidade a `g`;
- condicionamento da matriz;
- largura dos intervalos preditivos.

25. Validação quando não há futuro observado

No instante da decisão, não existem valores futuros para medir erro de forecast. Logo, o método não usa um backtest inexistente para escolher a janela atual.

A validação disponível naquele momento é interna e estrutural:

- coerência probabilística das hipóteses;
- evidência marginal no mesmo conjunto de dados;
- concentração ou dispersão da posterior;
- estabilidade a mudanças moderadas da prior;
- diagnóstico numérico;
- inspeção visual das alternativas materiais.

Quando novos meses forem observados, passam a existir avaliações prospectivas. É recomendável registrar cada forecast emitido sem alterá-lo e, posteriormente, comparar intervalo, cobertura, viés e erro realizado. Essa avaliação futura é diferente da inferência usada hoje.

26. Limitações e sinais de alerta

As probabilidades são condicionais ao conjunto de modelos e às suposições. Uma probabilidade alta não prova que a realidade seja exatamente constante, linear ou logarítmica.

Exigem atenção:

- sazonalidade mensal não modelada;
- resíduos autocorrelacionados;
- variância que cresce com o nível;
- outliers ou dados revisados;
- mais de uma mudança recente importante;
- janela corrente menor que `min_after`;
- choque conhecido que ainda não aparece nos dados;
- projeção em horizonte muito maior que o regime observado;
- alta sensibilidade a `g`;
- intervalo estreito causado por premissas inadequadas, e não por informação.

O método deve ser ampliado ou suspenso quando essas condições forem materiais.

27. Por que o método é menos heurístico que uma regra de janela

Uma regra como “usar sempre os últimos 12 meses” impõe a janela sem quantificar a dúvida. Um change point escolhido apenas pelo menor erro tende a premiar segmentos curtos. Uma inspeção puramente visual é útil, mas difícil de reproduzir em muitas séries.

Nesta formulação:

- todas as janelas competem no mesmo conjunto de observações;
- a complexidade é penalizada pela integração bayesiana;
- a preferência por ausência de ruptura é explícita;
- janela e modelo permanecem incertos;
- a incerteza de seleção chega ao forecast;
- escolhas anteriores são submetidas a análise de sensibilidade;
- a revisão humana é acionada por impacto, não por exceção informal.

Ainda existem escolhas de modelagem. A vantagem não é eliminar julgamento, mas expô-lo, parametrizá-lo e mostrar quando ele influencia a decisão.

28. Glossário

Coefficiente. Parâmetro que determina nível, inclinação ou forma da função.

Covariância. Matriz que mede dispersão conjunta. Na posterior condicional, ela é `sigma quadrado vezes Vn`.

Precisão. Inversa da covariância. Informações independentes aparecem como somas de precisões.

Prior. Distribuição que representa regularização e informação antes dos dados atuais.

Verossimilhança. Densidade dos dados como função dos parâmetros.

Posterior. Distribuição dos parâmetros depois de combinar prior e dados.

Evidência marginal. Probabilidade dos dados sob uma hipótese depois de integrar seus parâmetros.

Hipótese. Combinação de família funcional e início de regime.

Mistura preditiva. Soma ponderada das preditivas das hipóteses.

Incerteza de seleção. Variância decorrente da discordância entre hipóteses.

Intervalo preditivo. Faixa para uma nova observação, incluindo ruído futuro.

Conjunto crível de janelas. Menor conjunto construído por ordenação que acumula a massa posterior configurada.

29. Fórmulas essenciais em sequência

Padronização:

$$Z_t = \frac{y_t - c_y}{s_y}$$

Modelo dos dados:

$$\mathbf{z} = \mathbf{X}_h \boldsymbol{\beta}_h + \boldsymbol{\varepsilon}$$

g-prior:

$$\mathbf{V}_0 = g(\mathbf{X}^T \mathbf{X})^{-1}$$

Precisão posterior:

$$\mathbf{V}_n^{-1} = \mathbf{V}_0^{-1} + \mathbf{X}^T \mathbf{X}$$

Centro posterior:

$$\mathbf{b}_n = \mathbf{V}_n (\mathbf{V}_0^{-1} \mathbf{b}_0 + \mathbf{X}^T \mathbf{z})$$

Variância residual:

$$a_n = a_0 + n/2$$

$$d_n = d_0 + \frac{1}{2}(\mathbf{z}^T \mathbf{z} + \mathbf{b}_0^T \mathbf{V}_0^{-1} \mathbf{b}_0 - \mathbf{b}_n^T \mathbf{V}_n^{-1} \mathbf{b}_n)$$

Posterior da hipótese:

$$P(h \mid \mathbf{z}) \propto p(\mathbf{z} \mid h)P(h)$$

Preditiva de uma hipótese:

$$z_* \mid \mathbf{z}, h \sim t_{2a_n}(\mathbf{x}_*^T \mathbf{b}_n, q_h^2)$$

Mistura final:

$$p(y_* \mid \mathbf{y}) = \sum_h p(y_* \mid \mathbf{y}, h)P(h \mid \mathbf{y})$$

Decomposição da variância:

$$V_{total} = V_{dentro} + V_{entre}$$

30. Encadeamento final

$$\begin{aligned} & \mathbf{y} \rightarrow \mathbf{z} \rightarrow \{\mathbf{X}_h\} \rightarrow \\ & \{\text{posterior}_h, \text{evidencia}_h\} \rightarrow \{P(h \mid \mathbf{z})\} \rightarrow \\ & \text{mistura preditiva} \rightarrow \text{revisão se material} \end{aligned}$$

O resultado final preserva três formas de incerteza: ruído de uma nova observação, incerteza sobre os coeficientes e incerteza sobre qual janela e qual modelo representam o presente. Essa separação é o principal ganho conceitual do procedimento.